logistic-regression

November 20, 2024

```
[1]: import pandas as pd
     df_train =pd.read_csv("/content/Titanic_train.csv")
     df_test = pd.read_csv("/content/Titanic_test.csv")
[2]: df_train.shape
[2]: (891, 12)
[3]: df_test.shape
[3]: (418, 11)
[4]: df_train.head()
                     Survived
[4]:
        PassengerId
                               Pclass
                  1
                  2
     1
                             1
                                      1
     2
                  3
                             1
                                      3
     3
                   4
                             1
                                      1
                  5
                             0
                                      3
                                                        Name
                                                                 Sex
                                                                        Age
                                                                             SibSp
     0
                                   Braund, Mr. Owen Harris
                                                                male
                                                                      22.0
     1
        Cumings, Mrs. John Bradley (Florence Briggs Th... female 38.0
                                                                               1
     2
                                    Heikkinen, Miss. Laina
                                                                                 0
                                                              female
                                                                      26.0
     3
             Futrelle, Mrs. Jacques Heath (Lily May Peel)
                                                              female
                                                                      35.0
                                                                                 1
                                  Allen, Mr. William Henry
                                                                      35.0
                                                                                 0
                                                                male
                                      Fare Cabin Embarked
        Parch
                          Ticket
     0
                                                         S
            0
                       A/5 21171
                                   7.2500
                                             NaN
     1
            0
                        PC 17599
                                  71.2833
                                             C85
                                                         C
     2
               STON/02. 3101282
                                   7.9250
                                             NaN
                                                         S
     3
            0
                          113803
                                  53.1000
                                            C123
                                                         S
                                   8.0500
                                                         S
            0
                          373450
                                             NaN
[5]: df_train["code"] = 1
     df_test["code"] = 2
```

```
[6]: # merging the two data fils in one place
      data = pd.concat([df_train,df_test])
 [7]: data.shape
 [7]: (1309, 13)
      data.head()
 [8]:
         PassengerId
                      Survived Pclass
                            0.0
      0
                   1
                                      3
      1
                   2
                            1.0
                                      1
                   3
      2
                            1.0
                                      3
                   4
      3
                            1.0
                                      1
                   5
                            0.0
                                      3
                                                        Name
                                                                 Sex
                                                                       Age SibSp \
      0
                                    Braund, Mr. Owen Harris
                                                                male
                                                                      22.0
                                                                                 1
         Cumings, Mrs. John Bradley (Florence Briggs Th... female 38.0
                                                                               1
      1
      2
                                     Heikkinen, Miss. Laina
                                                              female
                                                                      26.0
                                                                                 0
      3
              Futrelle, Mrs. Jacques Heath (Lily May Peel)
                                                                      35.0
                                                              female
                                                                                 1
      4
                                   Allen, Mr. William Henry
                                                                male 35.0
         Parch
                           Ticket
                                      Fare Cabin Embarked code
      0
             0
                       A/5 21171
                                    7.2500
                                             NaN
                                                         S
                                                               1
                        PC 17599
                                   71.2833
                                             C85
                                                         C
                                                               1
      1
             0
      2
                                                         S
             0
                STON/02. 3101282
                                   7.9250
                                                               1
                                             NaN
      3
                                   53.1000 C123
                                                         S
                                                               1
             0
                           113803
      4
             0
                           373450
                                    8.0500
                                                         S
                                             NaN
                                                               1
 [9]: # verifying the train samples as code 1 and code 2
      data["code"].value_counts()
 [9]: code
      1
           891
      2
           418
      Name: count, dtype: int64
[10]: data.columns
[10]: Index(['PassengerId', 'Survived', 'Pclass', 'Name', 'Sex', 'Age', 'SibSp',
             'Parch', 'Ticket', 'Fare', 'Cabin', 'Embarked', 'code'],
            dtype='object')
[11]: data.info()
     <class 'pandas.core.frame.DataFrame'>
```

Index: 1309 entries, 0 to 417 Data columns (total 13 columns):

#	Column	Non-Null Count	Dtype		
0	PassengerId	1309 non-null	int64		
1	Survived	891 non-null	float64		
2	Pclass	1309 non-null	int64		
3	Name	1309 non-null	object		
4	Sex	1309 non-null	object		
5	Age	1046 non-null	float64		
6	SibSp	1309 non-null	int64		
7	Parch	1309 non-null	int64		
8	Ticket	1309 non-null	object		
9	Fare	1308 non-null	float64		
10	Cabin	295 non-null	object		
11	Embarked	1307 non-null	object		
12	code	1309 non-null	int64		
dtypes: $float6/(3)$ $int6/(5)$ object(5)					

dtypes: float64(3), int64(5), object(5)

memory usage: 143.2+ KB

[12]: data.describe()

F 4 6 7		_			_		
[12]:		PassengerId	Survived	Pclass	Age	SibSp	\
	count	1309.000000	891.000000	1309.000000	1046.000000	1309.000000	
	mean	655.000000	0.383838	2.294882	29.881138	0.498854	
	std	378.020061	0.486592	0.837836	14.413493	1.041658	
	min	1.000000	0.000000	1.000000	0.170000	0.000000	
	25%	328.000000	0.000000	2.000000	21.000000	0.000000	
	50%	655.000000	0.000000	3.000000	28.000000	0.000000	
	75%	982.000000	1.000000	3.000000	39.000000	1.000000	
	max	1309.000000	1.000000	3.000000	80.000000	8.000000	
		Parch	Fare	code			
	count	1309.000000	1308.000000	1309.000000			
	mean	0.385027	33.295479	1.319328			
	std	0.865560	51.758668	0.466394			
	min	0.000000	0.000000	1.000000			
	25%	0.000000	7.895800	1.000000			
	50%	0.000000	14.454200	1.000000			
	75%	0.000000	31.275000	2.000000			
	max	9.000000	512.329200	2.000000			

```
[13]: data['Age'].isna().sum()/len(data['Age'])*100
```

[13]: 20.091673032849503

```
[14]: #Data cleaning
data['Age'].fillna(data['Age'].median(),inplace=True)
```

<ipython-input-14-778811c38ca8>:3: FutureWarning: A value is trying to be set on
a copy of a DataFrame or Series through chained assignment using an inplace
method.

The behavior will change in pandas 3.0. This inplace method will never work because the intermediate object on which we are setting values always behaves as a copy.

For example, when doing 'df[col].method(value, inplace=True)', try using 'df.method({col: value}, inplace=True)' or df[col] = df[col].method(value) instead, to perform the operation inplace on the original object.

data['Age'].fillna(data['Age'].median(),inplace=True)

```
[15]: data['Fare'].fillna(data['Fare'].median(),inplace=True)
```

<ipython-input-15-ae37ac05ba0b>:1: FutureWarning: A value is trying to be set on
a copy of a DataFrame or Series through chained assignment using an inplace
method.

The behavior will change in pandas 3.0. This inplace method will never work because the intermediate object on which we are setting values always behaves as a copy.

For example, when doing 'df[col].method(value, inplace=True)', try using 'df.method({col: value}, inplace=True)' or df[col] = df[col].method(value) instead, to perform the operation inplace on the original object.

data['Fare'].fillna(data['Fare'].median(),inplace=True)

```
[16]: data['Cabin'].isna().sum()/len(data['Cabin'])*100
```

[16]: 77.46371275783041

```
[17]: data.drop('Cabin',axis=1,inplace=True)
```

[18]: (1307, 12)

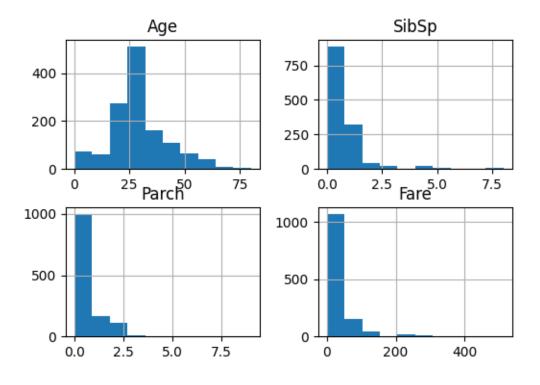
```
[19]: newdata.info()
```

<class 'pandas.core.frame.DataFrame'>
Index: 1307 entries, 0 to 417
Data columns (total 12 columns):

#	Column	Non-Null Count	Dtype		
0	PassengerId	1307 non-null	int64		
1	Survived	889 non-null	float64		
2	Pclass	1307 non-null	int64		
3	Name	1307 non-null	object		
4	Sex	1307 non-null	object		
5	Age	1307 non-null	float64		
6	SibSp	1307 non-null	int64		
7	Parch	1307 non-null	int64		
8	Ticket	1307 non-null	object		
9	Fare	1307 non-null	float64		
10	Embarked	1307 non-null	object		
11	code	1307 non-null	int64		
dtypes: float64(3), int64(5), object(4)					

memory usage: 132.7+ KB

```
[20]: import seaborn as sns
import matplotlib.pyplot as plt
#Histogram for all numerical variables
#numerical_features = data.select_dtypes(include=['int64', 'float64'])
numerical_features = newdata[["Age", "SibSp", "Parch", "Fare"]]
numerical_features.hist(figsize=(6, 4))
plt.show()
```

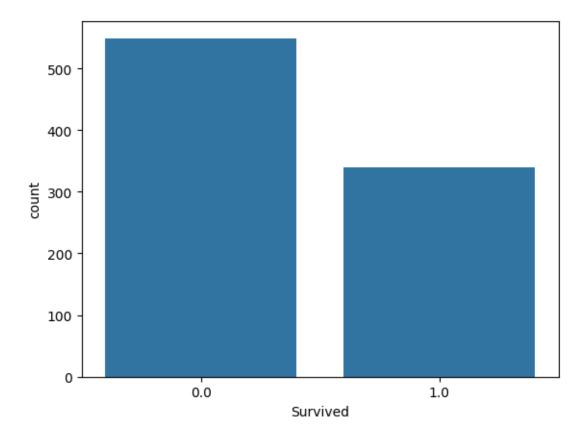


```
[21]: # Analyze correlation between features
    correlation_matrix = numerical_features.corr()
    plt.figure(figsize=(6, 4))
    sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm')
    plt.show()
```



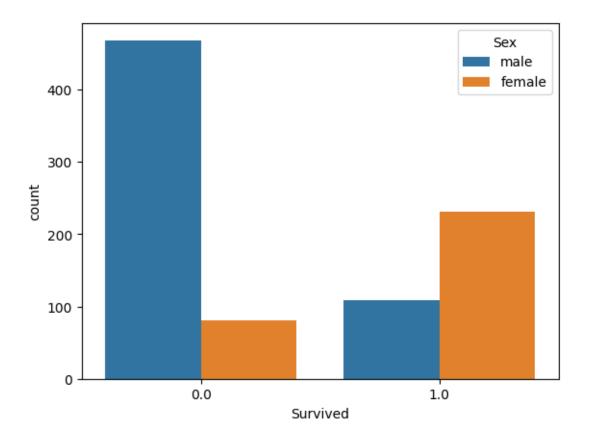
```
[29]: import seaborn as sns
# Reset the index of newdata
newdata = newdata.reset_index(drop=True)
# Now try to create the countplot
sns.countplot(x='Survived', data=newdata)
```

[29]: <Axes: xlabel='Survived', ylabel='count'>

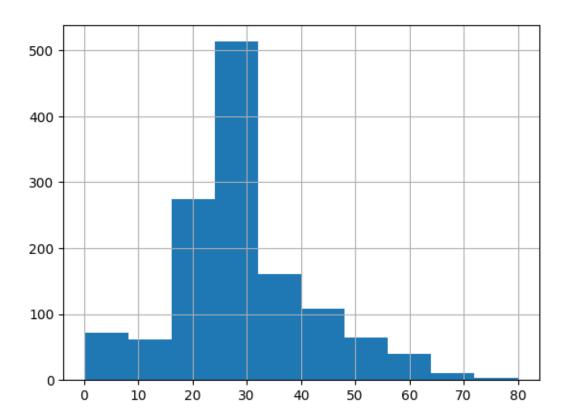


```
[30]: sns.countplot(x='Survived',data=newdata,hue='Sex')
```

[30]: <Axes: xlabel='Survived', ylabel='count'>



```
[31]: newdata.isna().sum()
[31]: PassengerId
                       0
      Survived
                      418
      Pclass
                        0
      Name
                        0
      Sex
                       0
      Age
                        0
      SibSp
                        0
      Parch
      Ticket
                       0
      Fare
                        0
      Embarked
                       0
      code
                       0
      dtype: int64
[32]: newdata["Age"].hist()
[32]: <Axes: >
```



```
[33]: newdata["Embarked"].value_counts()
[33]: Embarked
      \mathsf{S}
            914
      С
            270
      Q
            123
      Name: count, dtype: int64
[34]: newdata["Age"].describe()
[34]: count
                1307.000000
                   29.471821
      mean
      \operatorname{std}
                   12.881592
      min
                    0.170000
      25%
                   22.000000
      50%
                   28.000000
      75%
                   35.000000
      max
                   80.00000
      Name: Age, dtype: float64
[35]: newdata.isna().sum()
```

```
[35]: PassengerId
                        0
      Survived
                      418
      Pclass
                        0
      Name
                        0
      Sex
                        0
      Age
                        0
      SibSp
                        0
      Parch
                        0
      Ticket
                        0
      Fare
                        0
      Embarked
                        0
      code
                        0
      dtype: int64
[36]: newdata.head()
[36]:
         PassengerId
                      Survived Pclass
                            0.0
      0
                   1
                                      3
                   2
      1
                            1.0
                                      1
      2
                   3
                            1.0
                                      3
                   4
      3
                            1.0
                                      1
                   5
      4
                            0.0
                                      3
                                                        Name
                                                                  Sex
                                                                        Age SibSp \
                                    Braund, Mr. Owen Harris
      0
                                                                 male
                                                                       22.0
                                                                                  1
         Cumings, Mrs. John Bradley (Florence Briggs Th... female 38.0
      1
                                                                                1
      2
                                     Heikkinen, Miss. Laina
                                                              female
                                                                       26.0
                                                                                  0
              Futrelle, Mrs. Jacques Heath (Lily May Peel)
      3
                                                              female 35.0
                                                                                  1
      4
                                   Allen, Mr. William Henry
                                                                 male 35.0
                                                                                  0
                                                      code
         Parch
                                      Fare Embarked
                           Ticket
      0
                        A/5 21171
                                    7.2500
                         PC 17599
                                   71.2833
                                                   С
      1
             0
                                                         1
                                                   S
      2
             0
                STON/02. 3101282
                                    7.9250
                                                         1
      3
             0
                           113803
                                   53.1000
                                                   S
                                                         1
      4
             0
                                    8.0500
                                                   S
                           373450
                                                         1
     gender=pd.get_dummies(newdata['Sex'],drop_first=True)
[38]: newdata['Gender']=gender
[39]: newdata.columns
[39]: Index(['PassengerId', 'Survived', 'Pclass', 'Name', 'Sex', 'Age', 'SibSp',
              'Parch', 'Ticket', 'Fare', 'Embarked', 'code', 'Gender'],
            dtype='object')
```

```
[40]: newdata.head()
[40]:
         PassengerId
                      Survived Pclass
      0
                    1
                            0.0
                                       3
                    2
      1
                            1.0
                                       1
      2
                    3
                            1.0
                                      3
      3
                    4
                            1.0
                                      1
                    5
      4
                            0.0
                                       3
                                                                             SibSp \
                                                         Name
                                                                  Sex
                                                                        Age
                                    Braund, Mr. Owen Harris
      0
                                                                 male
                                                                       22.0
                                                                                  1
         Cumings, Mrs. John Bradley (Florence Briggs Th... female 38.0
      1
                                                                                1
                                     Heikkinen, Miss. Laina
                                                              female
                                                                                  0
              Futrelle, Mrs. Jacques Heath (Lily May Peel)
      3
                                                               female
                                                                                  1
      4
                                   Allen, Mr. William Henry
                                                                 male 35.0
                                                                                  0
         Parch
                           Ticket
                                      Fare Embarked
                                                      code
                                                            Gender
      0
             0
                        A/5 21171
                                    7.2500
                                                   S
                                                         1
                                                               True
      1
                         PC 17599
                                   71.2833
                                                   С
                                                              False
             0
                                                         1
      2
             0
                STON/02. 3101282
                                    7.9250
                                                   S
                                                         1
                                                              False
                                                   S
      3
             0
                           113803
                                   53.1000
                                                         1
                                                              False
      4
                                    8.0500
                                                   S
             0
                           373450
                                                               True
[41]: newdata.drop(newdata.columns[[3,4,8,10]],axis=1,inplace=True)
[42]: newdata.head()
[42]:
         PassengerId
                       Survived
                                 Pclass
                                           Age
                                                SibSp
                                                       Parch
                                                                  Fare
                                                                        code
                                                                              Gender
                                                                                 True
      0
                            0.0
                                      3 22.0
                                                    1
                                                                7.2500
                    1
      1
                   2
                            1.0
                                      1 38.0
                                                    1
                                                              71.2833
                                                                                False
      2
                    3
                            1.0
                                      3 26.0
                                                                7.9250
                                                                                False
                                                    0
                                                            0
                                      1 35.0
      3
                    4
                            1.0
                                                    1
                                                            0 53.1000
                                                                           1
                                                                                False
      4
                    5
                            0.0
                                      3 35.0
                                                    0
                                                                8.0500
                                                                           1
                                                                                 True
[43]: newdata.ndim
[43]: 2
[44]: from sklearn.preprocessing import StandardScaler
      SS = StandardScaler()
      newdata[["Age"]] = SS.fit_transform(newdata[["Age"]])
      newdata[["SibSp"]] = SS.fit_transform(newdata[["SibSp"]])
      newdata[["Parch"]] = SS.fit_transform(newdata[["Parch"]])
      newdata[["Fare"]] = SS.fit_transform(newdata[["Fare"]])
[45]: newdata.head()
```

```
[45]:
         PassengerId Survived Pclass
                                                      SibSp
                                                                Parch
                                             Age
                                     3 -0.580261 0.480272 -0.445407 -0.501839
                   1
                           0.0
                   2
      1
                           1.0
                                     1 0.662297 0.480272 -0.445407 0.736023
      2
                   3
                           1.0
                                     3 -0.269621 -0.479537 -0.445407 -0.488790
                           1.0
      3
                   4
                                     1 0.429318 0.480272 -0.445407 0.384512
      4
                   5
                           0.0
                                     3 0.429318 -0.479537 -0.445407 -0.486373
         code Gender
                 True
      0
            1
                False
      1
            1
      2
            1
                False
      3
            1
                False
      4
                 True
            1
[46]: df_new_train = newdata[newdata['code'] == 1]
      df_new_train.shape
[46]: (889, 9)
[47]: df new test = newdata[newdata['code'] == 2]
      df_new_test.shape
[47]: (418, 9)
[48]: x train = df new train[["Pclass", "Age", "SibSp", "Parch", "Fare", 'Gender']]
      y_train = df_new_train["Survived"]
[49]: x_test = df_new_test[["Pclass", "Age", "SibSp", "Parch", "Fare", 'Gender']]
      y_test = df_new_test["Survived"]
[50]: #IMPORTING LOGISTIC REGRESSION
      from sklearn.linear model import LogisticRegression
      lr=LogisticRegression()
[51]: lr.fit(x_train,y_train)
[51]: LogisticRegression()
[52]: lr.coef
[52]: array([[-1.04829233, -0.49408201, -0.34839432, -0.08170794, 0.15236021,
              -2.64243059]])
[53]: y_pred_train = lr.predict(x_train)
      y_pred_train
```

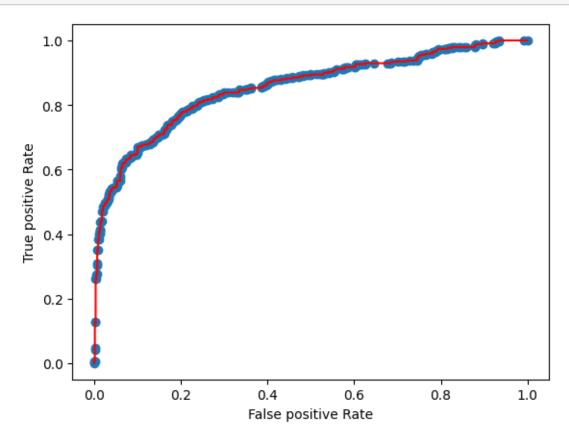
```
[53]: array([0., 1., 1., 1., 0., 0., 0., 0., 1., 1., 1., 1., 0., 0., 1., 1., 0.,
            0., 1., 1., 0., 0., 1., 1., 1., 0., 0., 0., 1., 0., 0., 1., 1., 0.,
            0., 0., 0., 0., 1., 1., 0., 1., 0., 1., 1., 0., 0., 1., 0., 1., 0.,
            0., 1., 1., 0., 1., 1., 0., 1., 0., 0., 0., 0., 1., 0., 1., 0., 0.,
            0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 1., 1., 1., 0.,
            0., 0., 1., 0., 0., 0., 0., 0., 0., 0., 1., 1., 0., 1., 0., 1.,
            0., 0., 0., 1., 0., 0., 1., 0., 1., 0., 1., 1., 0., 0., 0., 1., 1.,
            0., 0., 0., 1., 0., 0., 0., 0., 1., 0., 0., 0., 0., 1., 0., 0., 1.,
            0., 0., 1., 1., 1., 1., 0., 0., 0., 1., 0., 0., 0., 1., 0., 0.,
            0., 0., 1., 0., 0., 0., 0., 1., 0., 0., 0., 0., 1., 0., 1., 0., 0.,
            0., 1., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 1., 1., 1., 0.,
            0., 0., 1., 0., 1., 0., 1., 1., 0., 0., 1., 1., 0., 0., 0., 0., 0.,
            1., 0., 0., 1., 0., 0., 1., 0., 0., 1., 1., 0., 1., 0., 0., 0.,
            0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 1., 0., 1., 0.,
            0., 1., 1., 0., 0., 0., 1., 1., 0., 0., 0., 1., 0., 0., 1.,
            1., 1., 1., 1., 0., 0., 0., 1., 0., 0., 0., 1., 1., 1., 0., 1.,
            0., 1., 1., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 1.,
            1., 1., 0., 1., 0., 1., 0., 1., 1., 1., 1., 0., 0., 1., 0., 1., 1.,
            1., 0., 1., 1., 1., 1., 0., 0., 1., 1., 0., 1., 1., 0., 0., 1., 1.,
            0., 1., 0., 1., 1., 1., 0., 0., 0., 1., 0., 0., 1., 0., 0., 0.,
            1., 0., 0., 0., 1., 1., 1., 0., 0., 0., 1., 0., 0., 0., 0., 1., 1.,
            1., 1., 0., 0., 0., 0., 0., 1., 1., 1., 1., 0., 0., 0., 1., 1.,
            1., 1., 1., 0., 0., 1., 1., 0., 1., 0., 0., 0., 1., 0., 1., 0., 0.,
            0., 1., 1., 0., 1., 0., 0., 1., 0., 0., 1., 0., 1., 0., 0., 0., 0.,
            0., 0., 0., 1., 0., 0., 1., 1., 1., 0., 1., 0., 0., 0., 1., 0., 0.,
            1., 1., 0., 0., 1., 1., 1., 0., 0., 1., 1., 1., 0., 0., 1., 0., 0.,
            1., 0., 1., 1., 0., 1., 0., 0., 0., 0., 0., 0., 0., 0., 1., 1., 0.,
            0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 1., 1., 1., 1., 0.,
            0., 0., 1., 0., 0., 0., 1., 0., 1., 0., 0., 0., 0., 0., 0., 0.,
            0., 0., 1., 0., 1., 0., 0., 1., 1., 1., 1., 1., 1., 1., 0., 0., 0.,
            0., 0., 1., 0., 0., 1., 0., 1., 0., 1., 0., 0., 1., 0., 0., 1., 1.,
            0., 0., 1., 0., 0., 1., 1., 1., 0., 1., 0., 1., 1., 0., 0., 0., 0.,
            0., 1., 0., 0., 0., 1., 0., 0., 0., 1., 0., 1., 1., 1., 0., 0., 0.,
            0., 0., 1., 0., 0., 1., 0., 0., 0., 1., 0., 1., 0., 0., 1., 1., 1.,
            0., 1., 1., 0., 0., 0., 1., 0., 0., 0., 0., 0., 1., 0., 1., 0., 0.,
            1., 0., 0., 0., 1., 0., 1., 0., 0., 0., 1., 1., 1., 0., 0., 1.,
            0., 0., 1., 0., 1., 1., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0.,
            0., 0., 0., 0., 1., 1., 0., 0., 0., 0., 0., 1., 1., 0., 1., 0., 0.,
            0., 0., 1., 0., 1., 0., 1., 1., 0., 0., 0., 0., 0., 0., 0., 0., 0.,
            0., 0., 0., 0., 1., 1., 0., 0., 0., 0., 0., 1., 0., 1., 1.,
            1., 0., 0., 0., 0., 0., 0., 1., 0., 1., 0., 0., 0., 0., 0., 1.,
            0., 0., 1., 0., 1., 0., 0., 0., 1., 0., 1., 0., 1., 1., 0., 0., 0.,
            0., 1., 1., 0., 0., 1., 0., 0., 0., 0., 1., 1., 0., 1., 1., 0.,
            0., 0., 0., 0., 0., 1., 0., 0., 1., 0., 1., 0., 0., 0., 0., 1., 1.,
            0., 1., 0., 0., 0., 1., 0., 0., 0., 1., 0., 0., 0., 1., 0., 1.,
            1., 1., 0., 0., 0., 0., 1., 0., 1., 0., 0., 1., 0., 1., 1., 1., 1.,
            0., 0., 0., 1., 0., 0., 0., 0., 0., 1., 0., 0., 1., 1., 0., 1.,
```

```
0., 0., 0., 1., 0., 0., 1., 0., 0., 0., 0., 0., 1., 0., 0., 0.,
            1., 0., 0., 0., 1., 0., 0., 1., 0., 0., 0., 0., 0., 0., 1., 0., 0.,
            1., 1., 1., 1., 1., 0., 1., 0., 0., 0., 1., 0., 0., 1., 1., 1., 0.,
            0., 0., 1., 0., 0., 1., 1., 0., 0., 0., 1., 1., 0., 1., 0., 0., 0.,
            0., 1., 1., 1., 0.])
[54]: y_pred_test = lr.predict(x_test)
[57]: from sklearn.metrics import accuracy_score
      ac1 = accuracy_score(y_train,y_pred_train)
      print("Training accuracy:", round(ac1, 2)) # Use the round function instead of □
       → the round method
     Training accuracy: 0.8
     y_pred_test
[58]:
[58]: array([0., 0., 0., 0., 1., 0., 1., 0., 1., 0., 0., 0., 1., 0., 1., 1., 0.,
            0., 1., 0., 0., 0., 1., 1., 1., 0., 1., 0., 0., 0., 0., 0., 0., 1.,
            0., 0., 1., 1., 0., 0., 0., 1., 0., 1., 1., 0., 0., 0., 1., 1., 0.,
            0., 1., 1., 0., 0., 0., 0., 1., 0., 0., 0., 1., 1., 1., 1., 0.,
            0., 1., 1., 0., 1., 1., 1., 1., 0., 1., 0., 1., 0., 0., 0., 0., 0.,
            0., 1., 1., 1., 0., 1., 0., 1., 0., 1., 0., 1., 0., 1., 0.,
            0., 0., 1., 0., 0., 0., 0., 0., 1., 1., 1., 1., 0., 0., 1., 0.,
            1., 1., 0., 1., 0., 0., 1., 0., 0., 0., 0., 0., 0., 1., 0., 0.,
            0., 0., 1., 0., 0., 1., 0., 0., 0., 0., 1., 0., 1., 0., 1., 0., 0.,
            1., 0., 0., 1., 1., 0., 1., 1., 0., 1., 0., 0., 1., 0., 0., 1., 1.,
            0., 0., 0., 0., 0., 1., 1., 0., 1., 1., 0., 0., 1., 0., 1., 0., 1.,
            0., 0., 0., 0., 1., 0., 0., 0., 0., 1., 1., 0., 1., 1., 0., 0., 1.,
            0., 1., 1., 0., 1., 0., 0., 0., 0., 1., 0., 1., 0., 1., 0., 1.,
            0., 1., 0., 1., 1., 0., 1., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0.,
            1., 1., 1., 1., 0., 0., 0., 0., 1., 0., 1., 1., 1., 0., 1., 0., 0.,
            0., 0., 0., 1., 0., 0., 0., 1., 1., 0., 0., 0., 0., 1., 0., 0., 0.,
            1., 1., 0., 1., 0., 0., 0., 1., 0., 1., 1., 1., 0., 0., 1., 0.,
            0., 1., 1., 0., 0., 0., 0., 1., 0., 1., 0., 0., 0., 0., 0., 1., 1.,
            0., 0., 0., 0., 0., 0., 1., 1., 1., 0., 0., 0., 0., 0., 0., 0.,
            0., 1., 0., 1., 0., 0., 0., 1., 0., 0., 1., 0., 0., 0., 0., 0., 0.,
            0., 0., 0., 1., 0., 1., 0., 1., 0., 1., 1., 0., 0., 0., 0., 1., 0., 1.,
            0., 0., 1., 0., 1., 1., 0., 1., 0., 0., 1., 1., 0., 0., 1., 0., 0.,
            1., 1., 1., 0., 0., 0., 0., 1., 1., 0., 1., 0., 0., 0., 0., 1.,
             1., 0., 0., 0., 1., 0., 1., 0., 0., 1., 0., 1., 1., 0., 0., 0., 0.,
             1., 1., 1., 1., 0., 1., 0., 0., 0.])
[60]: from sklearn.metrics import confusion_matrix, accuracy_score, f1_score,
       →precision_score, recall_score
      acc = accuracy_score(y_train, y_pred_train)
```

0., 1., 1., 0., 0., 0., 0., 1., 0., 1., 0., 0., 0., 0., 0., 0., 1.,

```
prec = precision_score(y_train, y_pred_train)
      rec = recall_score(y_train, y_pred_train)
      f1 = f1_score(y_train, y_pred_train)
      results = pd.DataFrame([['Logistic Regression (Lasso)', acc, prec, rec, f1]],
                     columns = ['Model', 'Accuracy', 'Precision', 'Recall', 'F1
       Score'l)
      results
[60]:
                              Model Accuracy Precision
                                                            Recall F1 Score
      O Logistic Regression (Lasso)
                                     0.795276
                                                0.743827 0.708824 0.725904
[61]: from sklearn.metrics import roc curve
      from sklearn.metrics import roc_auc_score
[62]: from sklearn.metrics import roc_curve,roc_auc_score
      df_new_train["Y_proba"] = lr.predict_proba(x_train)[:,1]
      df_new_train.head()
     <ipython-input-62-5f7b67f5f85a>:2: SettingWithCopyWarning:
     A value is trying to be set on a copy of a slice from a DataFrame.
     Try using .loc[row_indexer,col_indexer] = value instead
     See the caveats in the documentation: https://pandas.pydata.org/pandas-
     docs/stable/user guide/indexing.html#returning-a-view-versus-a-copy
       df_new_train["Y_proba"] = lr.predict_proba(x_train)[:,1]
[62]:
        PassengerId Survived Pclass
                                            Age
                                                    SibSp
                                                              Parch
                                                                         Fare \
      0
                                    3 -0.580261 0.480272 -0.445407 -0.501839
                  1
                          0.0
                  2
      1
                           1.0
                                    1 0.662297 0.480272 -0.445407 0.736023
                  3
      2
                          1.0
                                    3 -0.269621 -0.479537 -0.445407 -0.488790
      3
                  4
                          1.0
                                    1 0.429318 0.480272 -0.445407 0.384512
                  5
                          0.0
                                    3 0.429318 -0.479537 -0.445407 -0.486373
      4
        code Gender Y_proba
           1
                True 0.099002
      0
      1
               False 0.891419
            1
      2
               False 0.649527
      3
               False 0.897235
            1
                True 0.085455
[63]: fpr,tpr,dummy = roc_curve(y_train,df_new_train["Y_proba"])
      import matplotlib.pyplot as plt
      plt.scatter(fpr,tpr)
      plt.plot(fpr,tpr,color='red')
      plt.xlabel("False positive Rate")
      plt.ylabel("True positive Rate")
```

```
plt.show()
print("AUC score:", roc_auc_score(y_train,df_new_train["Y_proba"]).round(3))
```



AUC score: 0.854

[64]: #1. What is the difference between precision and recall?

#Precision measures the accuracy of positive predictions, while recall measures \to the completeness of positive predictions.

#Recall: Recall, also known as sensitivity or true positive rate, is the ratio \hookrightarrow of correctly predicted positive observations to all actual positives. It \hookrightarrow measures the model's ability to find all the relevant cases within the data. \hookrightarrow It is calculated as:

[]: #2. What is cross-validation, and why is it important in binary classification?

#cross-validation is an essential technique in binary classification for \Box \Box obtaining reliable performance estimates, reducing overfitting, and \Box \Box optimizing model hyperparameters.